

**CENTRO UNIVERSITÁRIO DE BRASÍLIA - CEUB
CIÊNCIA DA COMPUTAÇÃO**

**LUCAS GONÇALVES BALDUINO - 22409139
JOÃO VICTOR RIOS - 22400050
ALEXSANDER MOTTA - 22407197
BEATRIZ VASCONCELLOS ESPINDOLA - 22408435
VINICIUS INOUE - 22308671**

PESQUISA E ANÁLISE DO TRABALHO INFORMAL DOMÉSTICO

PROJETO INTEGRADOR I - RELATÓRIO DE IMPLEMENTAÇÃO ETL

PROFESSORA ORIENTADORA: KADIDJA VALÉRIA REGINALDO DE OLIVEIRA

1. CONTEXTO DO NEGÓCIO E OBJETIVOS DO PROCESSO ETL

O presente documento detalha a modelagem e a implementação técnica da rotina de **ETL (Extract, Transform, Load)** para o sistema de análise da formalização do trabalho doméstico. O objetivo primordial é o cruzamento de fontes de dados distintas (baseadas em pesquisas governamentais) para validar a hipótese de que a formalização (como via MEI ou CLT) atua como ferramenta de proteção social, alinhando-se ao ODS 8 (Trabalho Decente e Crescimento Econômico).

As bases de dados brutas, exportadas em formato de tabelas dinâmicas do Excel (*Wide Format*), apresentavam células mescladas e cabeçalhos sobrepostos. Tais características exigiram a criação de um script automatizado em Python para normalização e construção de uma base estruturada ideal para o cruzamento de dados proposto no documento de Modelagem de Dados.

2. ENTIDADES E FONTES DE DADOS (EXTRACT)

A extração focou em quatro bases centrais referentes ao recorte de 1995 a 2015, segmentadas por Região e Cor/Raça.

Nome do Arquivo Físico	Título / Variável Analítica
DataTDRcomPrevi.xlsx - 7.5.csv	Proporção de Trabalhadoras que Contribuem para Previdência
DataTDRcomCLT.xlsx - 7.4.csv	Proporção de Trabalhadoras com Carteira Assinada
DataTDR-ResidenciasTrabalhadas.xlsx - 7.6.csv	Proporção de Trabalhadoras em Múltiplos Domicílios
DataTDR-RendimentoMedio.xlsx - 7.11a1.csv	Rendimento Médio Mensal das Trabalhadoras Domésticas

3. ESTRATÉGIA DE TRANSFORMAÇÃO (TRANSFORM)

A limpeza e manipulação dos dados seguiram rigorosos padrões de normalização. As etapas aplicadas via ecossistema Pandas incluíram:

- **Isolamento de Metadados:** Utilização do parâmetro `skiprows` para ignorar os títulos literais do Excel e forçar as variáveis geográficas e demográficas para o índice das colunas.

- **Preenchimento de Células (Forward Fill):** Resolução da ausência de dados na coluna "Cor/Raça". A função `.ffill()` foi utilizada para preencher os valores nulos com a categoria correspondente acima, corrigindo o erro da mesclagem vertical original.
- **Despivotamento (Melt):** Aplicação da técnica de despivotamento para converter o formato *Wide* (onde cada ano representava uma coluna) para o formato *Long/Tidy* (criando as colunas normalizadas `Ano` e `Valor`).
- **Coerção de Tipos e Limpeza de Strings:** Tratamento de separadores decimais padrão Brasil (vírgula) para formato numérico de ponto flutuante, viabilizando análises estatísticas rigorosas no futuro dashboard.

4. ARQUITETURA DO CÓDIGO FONTE (PYTHON & PANDAS)

Abaixo encontra-se a arquitetura modular desenvolvida em Python para orquestrar as transformações documentadas.

```

import pandas as pd
import numpy as np

def processar_e_limpar_indicador(caminho_arquivo, nome_indicador, pulo_linhas=2):
    # 1. EXTRACT: Leitura pulando o cabeçalho textual do Excel
    df = pd.read_csv(caminho_arquivo, skiprows=pulo_linhas)

    # Padronização de nomes estruturais
    df.columns.values[0] = 'Cor_Raca'
    df.columns.values[1] = 'Regiao'

    # 2. TRANSFORM: Tratamento de células fundidas e linhas fantasmas
    df['Cor_Raca'] = df['Cor_Raca'].ffill()
    df = df.dropna(subset=['Regiao'])
    df = df[df['Regiao'] != 'Região']

    # Identificação dos eixos cronológicos (anos)
    colunas_anos = [col for col in df.columns if col.isdigit()]

    # Normalização (Wide to Long)
    df_longo = df.melt(
        id_vars=['Cor_Raca', 'Regiao'],
        value_vars=colunas_anos,
        var_name='Ano',
        value_name='Valor'
    )

    # Tratamento de tipagem
    df_longo['Ano'] = df_longo['Ano'].astype(int)
    if df_longo['Valor'].dtype == 'object':
        df_longo['Valor'] = df_longo['Valor'].str.replace(',', '.', regex=False)

    df_longo['Valor'] = pd.to_numeric(df_longo['Valor'], errors='coerce')
    df_longo['Indicador'] = nome_indicador
    df_longo = df_longo.dropna(subset=['Valor'])

    return df_longo

```

5. CARGA E RESULTADOS (LOAD)

O arquivo consolidado resultante do processo de carga unifica todas as dimensões extraídas em uma tabela plana (*Flat Table*), compatível com a arquitetura de JSON orientada a eventos para o dashboard (conforme especificado no documento de Modelagem de Dados). O artefato final é livre de formatações anômalas e pronto para consumo analítico.

Indicador	Cor_Raca	Regiao	Ano	Valor
Proporção com Carteira Assinada	Total	Brasil	1995	17.78
Rendimento Médio Mensal	Branca	Sul	2015	852.10

Com este fluxo de ETL consolidado, a equipe garante a robustez arquitetural e metodológica necessária para prosseguir com a implementação do front-end e dos indicadores de desempenho da disciplina.